Maintenance prédictive et Machine Learning explicable

Détection des défaillances d'équipements industriels sous forte asymétrie de classes : comparaison de trois familles de modèles et interprétation par valeurs de Shapley

> *« Dans quelle mesure des modèles de Machine Learning permettent-ils de détecter efficacement les risques de panne, et quels facteurs influencent le plus leurs prédictions ? »*

AUTEUR	**Ponnoussamy Valentin**
JEU DE DONNÉES	**AI4I 2020 Predictive Maintenance Dataset** — UCI Machine Learning Repository
MÉTHODES	Logistic Regression · Random Forest · XGBoost · SHAP
ENVIRONNEMENT	Python · scikit-learn · XGBoost · SHAP · Pandas
DÉPÔT	github.com/Yvngval/Predictive-Maintenance-Explainable-ML-
DATE	Octobre 2026

Sommaire

1. Résumé 3

2. Problématique 3

2.1 Contexte industriel 3

2.2 Question de recherche et hypothèse 3

3. Données 4

3.1 Description 4

3.2 Sélection des variables et fuite de données 4

3.3 Anomalies d'étiquetage 5

3.4 Structure du signal 5

4. Méthodologie 6

4.1 Protocole expérimental 6

4.2 Choix des métriques 6

4.3 Justification du traitement du déséquilibre 6

5. Résultats 7

5.1 Validation croisée 7

5.2 Performances sur l'échantillon de test 7

5.3 Portée opérationnelle 8

5.4 Comparaison ROC-AUC et PR-AUC 9

6. Validation de l'hypothèse 10

7. Interprétation du modèle 11

7.1 Hiérarchie des variables 11

7.2 Formes fonctionnelles 12

8. Analyse des erreurs 14

8.1 Les faux négatifs sont des défaillances par usure 14

8.2 Les faux positifs sont des états dégradés qui n'ont pas dégénéré 14

8.3 Sur le seuil de décision 15

9. Limites 16

9.1 Limites liées aux données 16

9.2 Limites liées au protocole 16

10. Conclusion 17

10.1 Réponse à la question de recherche 17

10.2 Modèle retenu 17

10.3 Apport méthodologique 17

10.4 Prolongements 17

Références 18

1. Résumé

Cette étude évalue la capacité de modèles de Machine Learning à anticiper les défaillances d'équipements industriels à partir de variables de fonctionnement, et identifie les facteurs qui déterminent leurs prédictions.

Trois familles de modèles — régression logistique, forêt aléatoire et gradient boosting — sont comparées sur le jeu de données AI4I 2020 (10 000 observations, 3,39 % de pannes), selon un protocole identique : séparation stratifiée, pondération des classes, validation croisée en cinq blocs et évaluation par PR-AUC, précision et rappel.

XGBoost obtient les meilleures performances (PR-AUC = 0,813 contre 0,774 pour la forêt aléatoire et 0,382 pour la régression logistique). L'analyse par valeurs de Shapley attribue 75 % de l'importance aux trois variables mécaniques — couple, usure de l'outil et vitesse de rotation — et met en évidence des relations non linéaires à effet de seuil.

L'hypothèse initiale, selon laquelle les modèles non linéaires produiraient davantage de faux positifs, est **infirmée** : la régression logistique en génère neuf fois plus que XGBoost. Ce résultat s'explique par la géométrie du problème, les défaillances survenant dans deux régimes mécaniques opposés qu'aucune frontière linéaire ne peut isoler simultanément.

2. Problématique

2.1 Contexte industriel

Les défaillances non planifiées d'équipements immobilisent les lignes de production et génèrent deux postes de coûts distincts : la perte de production pendant l'arrêt, et le surcoût d'une intervention en urgence comparée à une maintenance programmée.

L'anticipation de ces défaillances permettrait de planifier les interventions. La difficulté réside dans l'arbitrage temporel : intervenir trop tôt conduit à remplacer des composants encore fonctionnels et à immobiliser inutilement la machine ; intervenir trop tard laisse survenir la panne que l'on cherchait à prévenir. Cet arbitrage structure l'ensemble de la démarche, du choix des métriques d'évaluation au réglage du seuil de décision.

2.2 Question de recherche et hypothèse

> ***Question de recherche.*** *Dans quelle mesure des modèles de Machine Learning permettent-ils de détecter efficacement les risques de panne, et quels facteurs influencent le plus leurs prédictions ?*

> ***Hypothèse.*** *Les modèles non linéaires devraient détecter les pannes plus efficacement que la régression logistique, mais pourraient produire davantage de faux positifs.*

3. Données

3.1 Description

Le jeu de données AI4I 2020, issu du UCI Machine Learning Repository, comporte 10 000 observations décrites par 14 variables. Il ne présente ni valeur manquante ni doublon. La variable cible `Machine failure` recense **339 défaillances, soit 3,39 % des observations**.

Les données sont **synthétiques** : elles reproduisent des comportements industriels réalistes au moyen de règles de génération déterministes, sans provenir de capteurs réels. Cette caractéristique est prise en compte dans la discussion des limites.

3.2 Sélection des variables et fuite de données

Sur les treize variables disponibles hors cible, six sont retenues. Les exclusions reposent sur deux justifications distinctes.

Les identifiants. `UDI` et `Product ID` comptent chacun 10 000 valeurs distinctes pour 10 000 observations. Ils ne portent aucune information généralisable.

Les indicatrices de mode de défaillance. Les variables `TWF`, `HDF`, `PWF`, `OSF` et `RNF` désignent le *type* de défaillance constaté. Elles ne sont renseignées qu'après la survenue de la panne et ne seraient donc pas disponibles au moment où la prédiction devrait être produite. Les conserver comme variables explicatives constituerait une **fuite de données** : le modèle afficherait des performances quasi parfaites en test tout en étant inopérant en conditions réelles.

Variable	Rôle	Nature
`Type`	Explicative	Catégorielle (L / M / H)
`Air temperature [K]`	Explicative	Continue
`Process temperature [K]`	Explicative	Continue
`Rotational speed [rpm]`	Explicative	Continue
`Torque [Nm]`	Explicative	Continue
`Tool wear [min]`	Explicative	Continue
`Machine failure`	Cible	Binaire
`UDI`, `Product ID`	Exclues	Identifiants
`TWF`, `HDF`, `PWF`, `OSF`, `RNF`	Exclues	Fuite de données

3.3 Anomalies d'étiquetage

Le décompte des modes de défaillance (373 occurrences) excède celui des pannes enregistrées (339). Trois phénomènes l'expliquent : 24 observations cumulent plusieurs modes simultanés ; 18 observations portent un mode levé sans étiquette de panne, toutes relevant de `RNF` (*Random Failure*), défaillance aléatoire non prédictible par construction ; 9 pannes sont déclarées sans qu'aucun mode ne soit identifié, ce qui constitue un défaut d'étiquetage.

Ces observations sont conservées. Les retirer reviendrait à épurer le jeu de test à partir d'une information indisponible en production. Les neuf pannes sans cause identifiable abaissent toutefois mécaniquement le plafond de performance atteignable.

3.4 Structure du signal

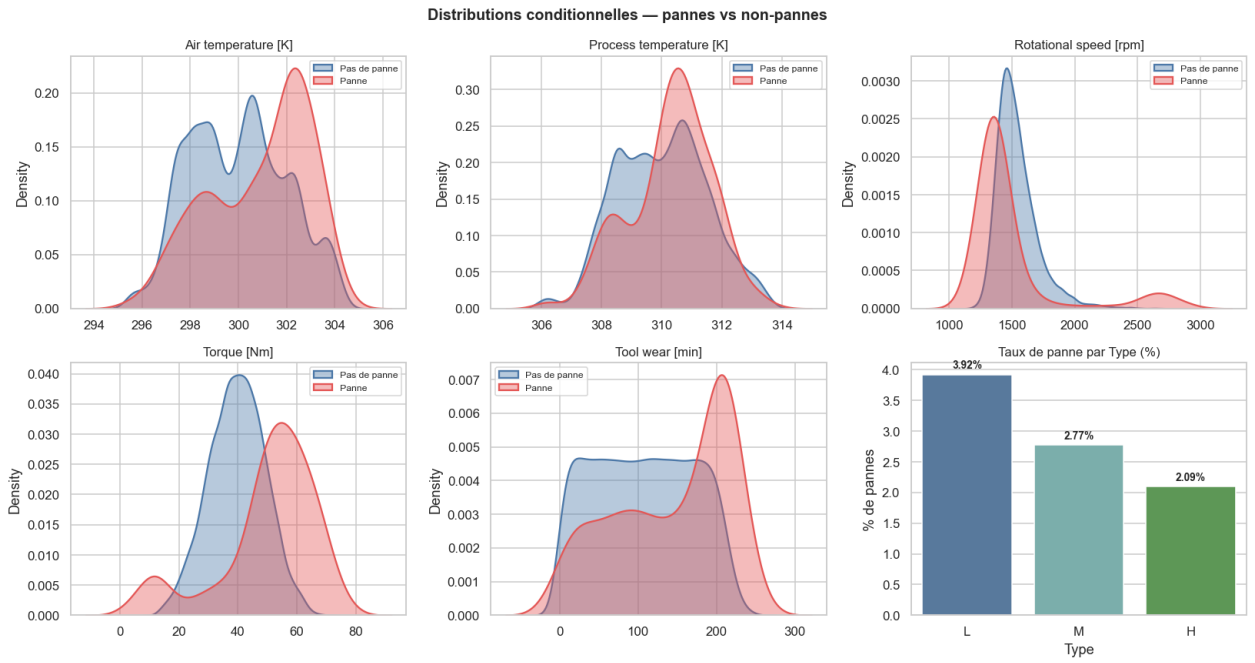


Figure 1. Distributions des variables de fonctionnement selon la survenue d'une défaillance. Le couple et l'usure de l'outil séparent nettement les deux classes ; les températures se recouvrent largement.

Trois variables discriminent visiblement les classes. Le couple est en moyenne 27 % plus élevé en situation de panne, avec une **distribution conditionnelle bimodale** : une masse principale entre 40 et 70 Nm et un second groupe en deçà de 15 Nm. La vitesse de rotation présente un profil miroir, cohérent avec la relation mécanique liant ces deux grandeurs. L'usure de l'outil est en moyenne 35 % plus élevée avant une défaillance.

Les corrélations linéaires avec la cible demeurent cependant faibles (maximum 0,191 pour le couple), ce qui suggère que les défaillances résultent de **combinaisons de conditions** plutôt que du franchissement d'un seuil sur une variable isolée.

Deux colinéarités fortes sont relevées : entre les deux températures ($r \approx 0{,}88$) et entre couple et vitesse de rotation ($r \approx -0{,}88$). Elles affectent l'interprétation des coefficients de la régression logistique et la répartition de l'importance entre variables redondantes.

4. Méthodologie

4.1 Protocole expérimental

1. **Séparation train/test stratifiée** (80 / 20), la stratification préservant le taux de défaillance dans les deux échantillons.
2. **Encodage** de la variable catégorielle `Type` en indicatrices, la modalité `H` servant de référence.
3. **Standardisation** appliquée à la seule régression logistique, par pipeline. Les modèles à base d'arbres procédant par seuils univariés sont invariants aux transformations monotones ; ils sont entraînés sur les variables dans leurs unités d'origine, ce qui préserve la lisibilité des graphiques d'interprétation.
4. **Compensation du déséquilibre** par pondération inversement proportionnelle à la fréquence des classes, appliquée identiquement aux trois modèles afin de garantir l'équité de la comparaison.
5. **Validation croisée stratifiée** en cinq blocs sur l'échantillon d'entraînement.
6. **Évaluation** sur l'échantillon de test réservé.
7. **Ajustement du seuil de décision** à partir des prédictions hors échantillon, le jeu de test n'étant jamais consulté pour ce réglage.
8. **Interprétation** du meilleur modèle par valeurs de Shapley et analyse des erreurs.

4.2 Choix des métriques

Avec 3,39 % de défaillances, un classifieur prédisant systématiquement l'absence de panne atteint **96,6 % d'accuracy** sans détecter la moindre défaillance. L'accuracy est donc écartée.

La **PR-AUC** est retenue comme métrique principale. Contrairement à la ROC-AUC, elle ne bénéficie pas mécaniquement de l'abondance de vrais négatifs et reflète fidèlement la difficulté du problème déséquilibré. Étant indépendante du seuil, elle mesure le pouvoir de discrimination intrinsèque.

La **précision** et le **rappel** sont examinés conjointement : ils traduisent directement l'arbitrage métier, le rappel mesurant la part des défaillances détectées et la précision la part des alertes justifiées.

4.3 Justification du traitement du déséquilibre

Avec 28,5 observations négatives pour une positive, un modèle optimisant une perte non pondérée a intérêt à ignorer la classe minoritaire. La pondération des classes est préférée à un ré-échantillonnage de type SMOTE, qui introduirait des observations synthétiques dans un jeu de données déjà simulé.

5. Résultats

5.1 Validation croisée

Modèle	PR-AUC moyenne	Écart-type
Logistic Regression	0,441	± 0,030
Random Forest	0,750	± 0,037
XGBoost	0,751	± 0,036

L'écart entre la régression logistique et les deux modèles d'ensemble excède largement la dispersion entre blocs : il est robuste. En revanche, l'écart entre forêt aléatoire et XGBoost (0,001) est très inférieur à leur écart-type respectif : **ces deux modèles sont statistiquement indiscernables** à ce stade.

5.2 Performances sur l'échantillon de test

L'échantillon de test comporte 2 000 observations, dont 68 défaillances.

Modèle	Precision	Recall	F1	PR-AUC	ROC-AUC
Logistic Regression	0,142	0,824	0,242	0,382	0,907
Random Forest	0,808	0,618	0,700	0,774	0,971
XGBoost	0,609	0,824	0,700	**0,813**	0,972
XGBoost — seuil ajusté	0,828	0,706	0,762	0,813	0,972

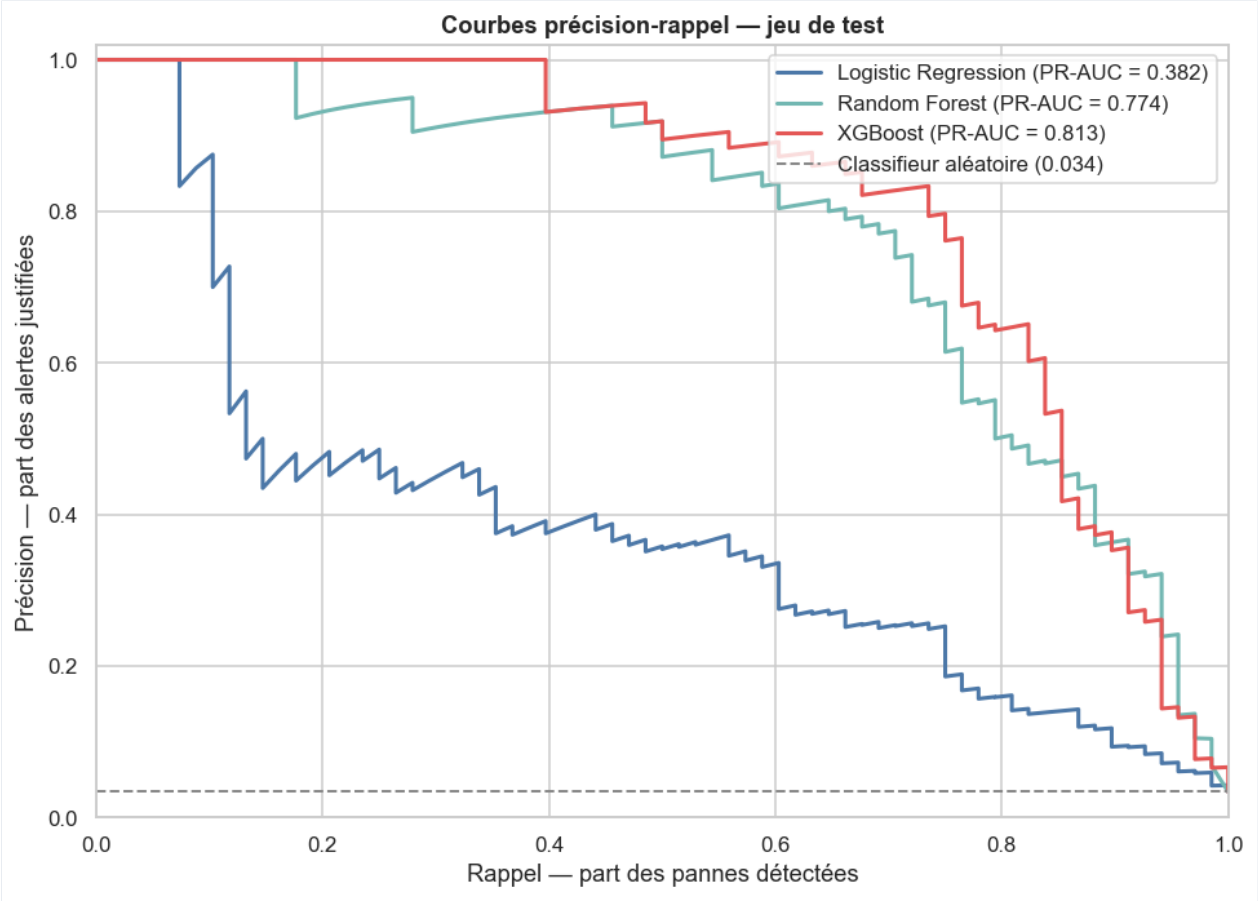


Figure 2. Courbes précision-rappel sur l'échantillon de test. La ligne horizontale représente le niveau atteint par un classifieur aléatoire (0,034).

La régression logistique échoue par la précision, non par le rappel. Son rappel (0,824) égale celui de XGBoost : elle détecte autant de défaillances que le meilleur modèle. C'est sa précision qui s'effondre à 0,142 — moins d'une alerte sur sept est justifiée.

Forêt aléatoire et XGBoost atteignent un F1 identique (0,700) par des compromis opposés. La première privilégie la précision (0,808) au détriment du rappel (0,618), le second fait l'inverse. Cette identité de score illustre la limite d'une métrique agrégée considérée isolément.

5.3 Portée opérationnelle

Modèle	Défaillances détectées	Défaillances manquées	Fausses alertes	Interventions déclenchées
Logistic Regression	56 / 68	12	339	395
Random Forest	42 / 68	26	10	52
XGBoost	56 / 68	12	36	92
XGBoost — seuil ajusté	48 / 68	20	10	58

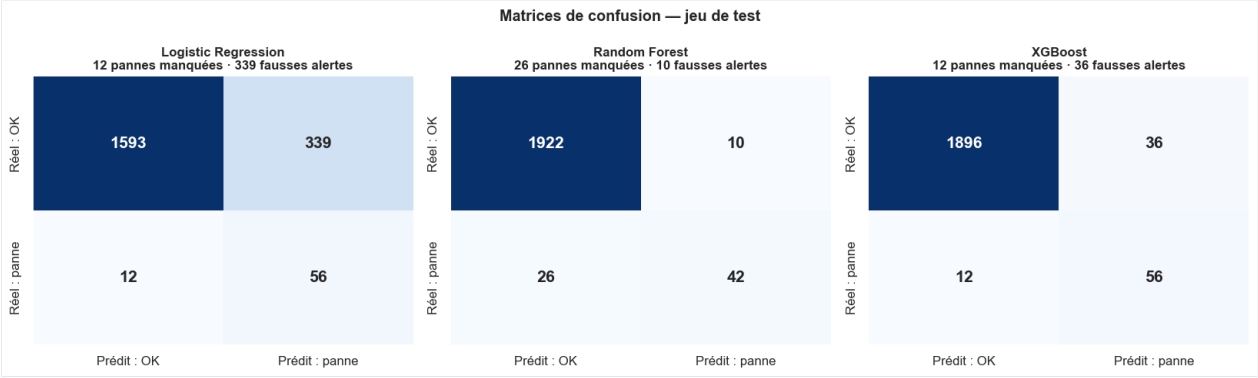


Figure 3. Matrices de confusion des trois modèles sur l'échantillon de test, au seuil de décision de 0,50.

Traduite en termes opérationnels, la régression logistique déclencherait **395 interventions pour 56 défaillances réelles**, soit près de sept déplacements de maintenance par panne évitée — un dispositif qui serait abandonné en quelques semaines. La forêt aléatoire présente le défaut symétrique : 10 fausses alertes seulement, mais plus d'une défaillance sur trois non détectée.

5.4 Comparaison ROC-AUC et PR-AUC

Les trois modèles affichent une ROC-AUC élevée, jusqu'à 0,907 pour la régression logistique — qui n'émet pourtant qu'une alerte justifiée sur sept. La ROC-AUC intègre le taux de vrais négatifs, abondants ici, et produit une image flatteuse d'un modèle inexploitable. La PR-AUC du même modèle chute à 0,382 et reflète correctement la situation.

Ce contraste constitue la **justification empirique du choix de la PR-AUC** comme métrique principale sous forte asymétrie de classes.

6. Validation de l'hypothèse

RÉSULTAT PRINCIPAL

L'hypothèse est **confirmée sur la détection et infirmée sur les faux positifs**.

Les modèles non linéaires discriminent effectivement bien mieux : la PR-AUC passe de 0,382 à 0,813. Mais loin de produire *davantage* de faux positifs, XGBoost en génère **neuf fois moins** que la régression logistique — 36 contre 339.

L'explication tient à la **géométrie du problème** plutôt qu'à la capacité intrinsèque des modèles.

L'analyse exploratoire a établi que les défaillances surviennent dans deux régimes mécaniques opposés : surcharge (couple élevé, vitesse faible) et sous-charge (couple faible, vitesse élevée). Ces deux régions occupent les extrémités opposées d'une même variable.

La régression logistique ne peut séparer les classes que par un hyperplan, c'est-à-dire par un effet monotone sur chaque variable. Aucune frontière de ce type ne peut isoler simultanément deux régions situées aux deux extrémités d'un axe sans englober l'espace intermédiaire — précisément celui où se concentre l'essentiel des observations saines. Pour capter les deux régimes, le modèle est contraint d'élargir massivement sa zone d'alerte, ce qui produit les 339 faux positifs observés.

Les modèles à base d'arbres, en partitionnant récursivement l'espace des variables, isolent chaque régime séparément sans inclure la zone centrale.

Ce n'est donc pas la « puissance » du modèle qui explique l'écart, mais **l'adéquation entre la forme de sa frontière de décision et la structure géométrique du problème**.

7. Interprétation du modèle

7.1 Hiérarchie des variables

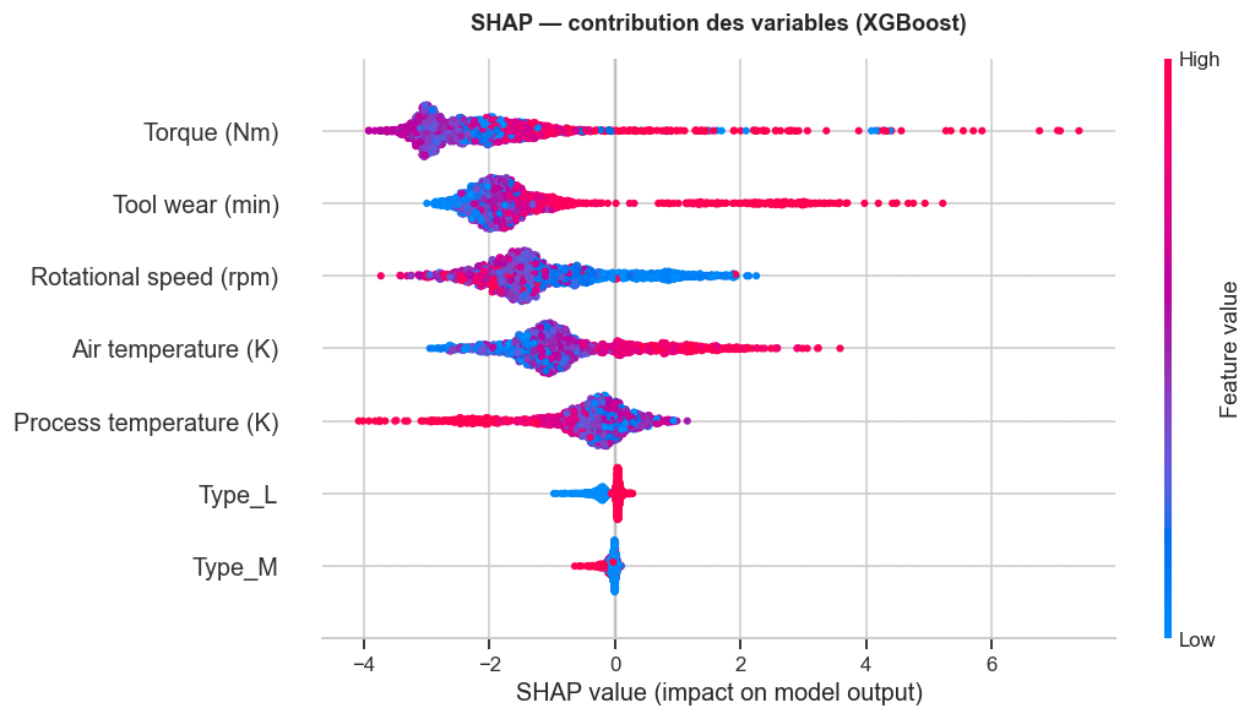


Figure 4. Contribution des variables aux prédictions de XGBoost (valeurs de Shapley). Chaque point représente une observation ; la couleur code la valeur de la variable, l'abscisse sa contribution au score de défaillance.

Variable	Part de l'importance totale
Torque (Nm)	30,8 %
Tool wear (min)	25,1 %
Rotational speed (rpm)	18,8 %
Air temperature (K)	14,9 %
Process temperature (K)	7,7 %
Type (L + M)	2,7 %

Les trois variables mécaniques concentrent **75 % de l'importance totale**, confirmant et quantifiant ce que suggéraient les distributions conditionnelles.

La qualité du produit ne pèse que 2,7 %, alors que le taux de défaillance brut est presque deux fois plus élevé pour les produits de qualité inférieure (3,92 % contre 2,09 %). L'effet est en grande partie **médié par les conditions de fonctionnement** : les produits de faible qualité sont usinés dans des régimes plus contraignants, déjà décrits par le couple et la vitesse. Une fois ces variables connues,

`Type` n'apporte plus qu'une information résiduelle. Ce résultat illustre la distinction entre corrélation marginale et contribution conditionnelle, et constitue un apport propre à l'analyse par valeurs de Shapley.

La température du process contribue deux fois moins que la température de l'air (7,7 % contre 14,9 %). Ces deux variables étant corrélées à 0,88, elles portent une information largement redondante : le modèle s'appuie préférentiellement sur l'une et n'exploite de la seconde que le résidu.

7.2 Formes fonctionnelles

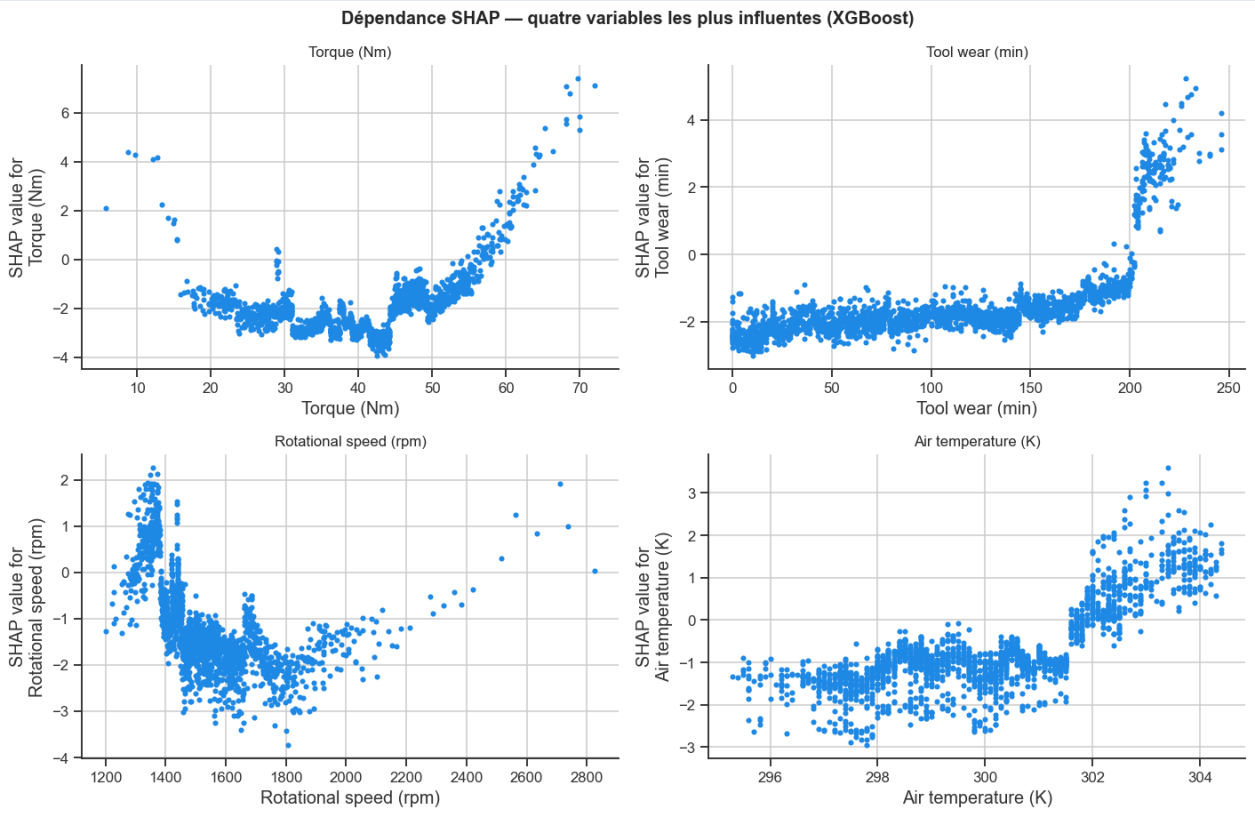


Figure 5. Dépendance SHAP des quatre variables les plus influentes. L'abscisse représente la valeur de la variable, l'ordonnée sa contribution au score de défaillance.

Les quatre variables présentent des relations franchement non linéaires, que la régression logistique était par construction incapable de représenter.

Le couple dessine une courbe en U. La contribution est minimale autour de 40–45 Nm — le régime nominal — et croît aux deux extrémités : fortement au-delà de 50 Nm, plus modérément en deçà de 15 Nm. C'est la confirmation quantitative des deux régimes de défaillance. Une frontière linéaire, imposant un effet monotone, doit choisir un sens et manque nécessairement l'un des deux.

L'usure de l'outil produit un effet de seuil. La contribution demeure plate et négative sur tout l'intervalle 0–200 minutes, puis bascule brutalement au-delà. Le modèle a donc appris un **seuil de remplacement implicite**, cohérent avec la logique métier d'un outil se dégradant sans conséquence jusqu'à un point de rupture.

La vitesse de rotation reproduit le U du couple, inversé, les deux grandeurs étant mécaniquement liées à puissance donnée. **La température de l'air agit également par seuil**, avec une bascule autour de 301,5 K.

Ces quatre formes — deux courbes en U et deux effets de seuil — expliquent en une figure l'écart de performance entre familles de modèles.

8. Analyse des erreurs

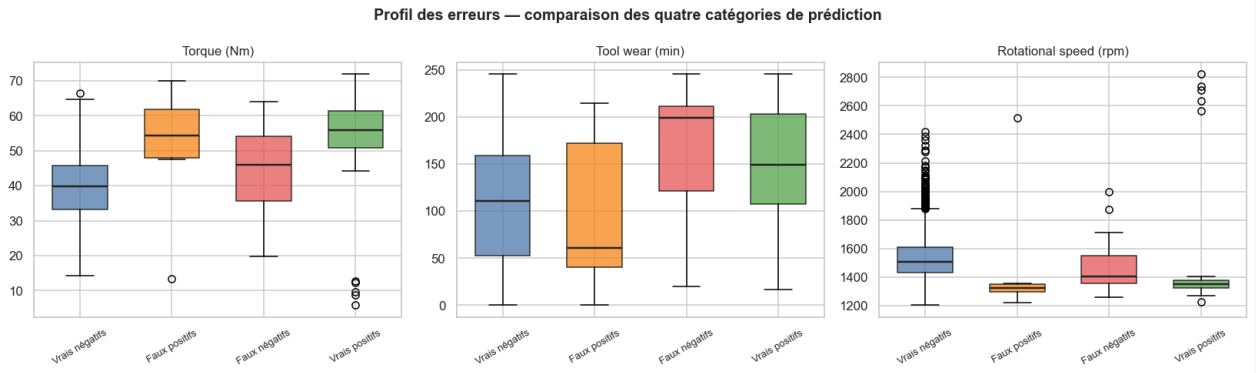


Figure 6. Dispersion des variables de fonctionnement selon les quatre catégories de prédiction, pour XGBoost au seuil ajusté.

Variable	Vrais négatifs	Faux positifs	Faux négatifs	Vrais positifs
Couple (Nm)	39,5	51,9	44,7	52,4
Usure de l'outil (min)	107,5	94,4	170,3	146,3
Vitesse de rotation (rpm)	1 539	1 430	1 476	1 481
Température de l'air (K)	300,0	301,6	300,9	300,7

8.1 Les faux négatifs sont des défaillances par usure

L'usure moyenne des faux négatifs (170 minutes) est la plus élevée des quatre catégories — supérieure même à celle des défaillances correctement détectées (146 minutes). Leur couple demeure en revanche modéré (44,7 Nm contre 52,4 pour les vrais positifs).

L'examen des cas individuels est sans ambiguïté : des usures de 198, 200, 203, 207, 221 et 222 minutes associées à des couples de 19,8 à 41,9 Nm, c'est-à-dire des conditions mécaniques parfaitement ordinaires.

Ces observations correspondent à des défaillances par usure d'outil, survenant en régime normal après une durée d'utilisation prolongée. **Le modèle les manque parce qu'il s'appuie prioritairement sur la contrainte mécanique instantanée** — le couple représente 31 % de son importance — alors que ces défaillances relèvent d'un processus cumulatif.

8.2 Les faux positifs sont des états dégradés qui n'ont pas dégénéré

Le profil des faux positifs est celui d'une défaillance : couple le plus élevé des quatre catégories (51,9 Nm, supérieur même à celui des vrais positifs), vitesse de rotation la plus basse, température de l'air la plus haute. Ce sont des points de fonctionnement en surcharge mécanique qui n'ont simplement pas produit de défaillance.

Ces cas ne constituent donc pas des erreurs au sens strict : **ils sont physiquement indiscernables des défaillances sur la base des variables disponibles**. Du point de vue métier, une alerte sur ces points relève davantage de la détection précoce que du faux positif.

8.3 Sur le seuil de décision

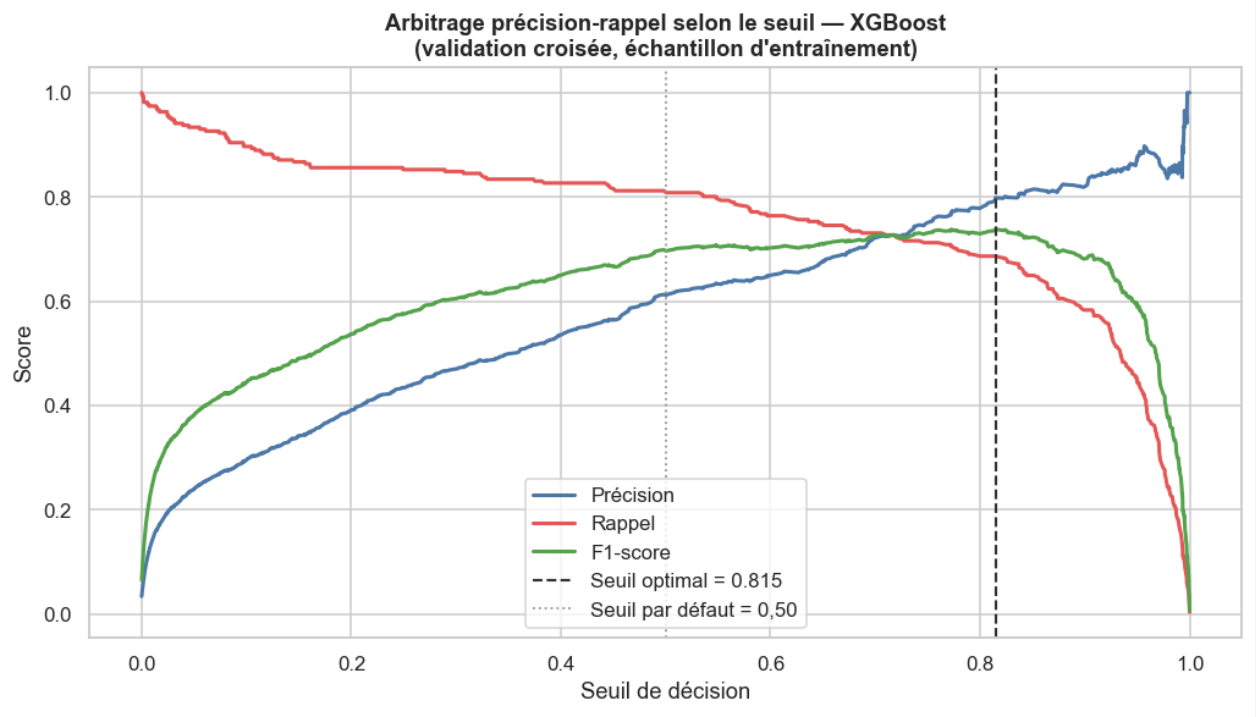


Figure 7. Évolution de la précision, du rappel et du F1 selon le seuil de décision, estimée par validation croisée sur l'échantillon d'entraînement.

Le seuil optimal identifié (0,815) excède nettement la convention de 0,50. Ce décalage résulte directement de la pondération des classes : en multipliant par 28,5 le poids des défaillances dans la fonction de perte, la procédure déplace mécaniquement les probabilités prédites vers le haut.

L'ajustement fait progresser le F1 de 0,700 à 0,762 et divise les fausses alertes par plus de trois, mais **huit défaillances supplémentaires échappent à la détection**.

Le F1 pondère identiquement précision et rappel, ce qui ne repose sur aucune justification métier. Dans un contexte industriel réel, le seuil devrait dériver du rapport entre le coût d'un arrêt de production subi et celui d'une intervention préventive inutile. Si une défaillance coûte dix fois plus cher qu'une fausse alerte, le seuil de 0,50 — plus favorable au rappel — demeure préférable. **Le seuil constitue un paramètre métier, non une constante statistique.**

9. Limites

9.1 Limites liées aux données

Caractère synthétique. Les relations entre variables sont générées par des règles déterministes, plus régulières que ce qu'on observerait sur des capteurs réels soumis au bruit de mesure, à la dérive d'étalonnage et aux valeurs manquantes. La validité externe des conclusions reste à établir.

Défauts d'étiquetage. Neuf défaillances sur 339 ne sont associées à aucun mode identifié, et dix-huit observations portent un mode `RNF` — défaillance aléatoire, non prédictible par construction — sans étiquette de panne. Ces cas abaissent le plafond de performance atteignable.

Effectif de la classe positive. L'échantillon de test ne comporte que 68 défaillances. Chaque observation mal classée déplace le rappel de 1,5 point : les intervalles de confiance sur les métriques sont larges et les écarts faibles entre modèles doivent être interprétés avec prudence. C'est précisément le cas de l'écart entre forêt aléatoire et XGBoost.

Hypothèse d'indépendance. Les observations sont supposées indépendantes. S'il s'agissait de relevés successifs d'une même machine, cette hypothèse serait violée et la séparation aléatoire train/test produirait une fuite temporelle.

9.2 Limites liées au protocole

Absence d'optimisation des hyperparamètres. Aucune recherche systématique n'a été conduite. Les valeurs retenues constituent des choix raisonnables mais non justifiés empiriquement.

Absence d'ingénierie de variables. Les modes de défaillance du jeu de données sont définis à partir de grandeurs dérivées — puissance mécanique (produit du couple et de la vitesse angulaire), écart entre les deux températures. Les construire explicitement améliorerait vraisemblablement la détection, en particulier celle des défaillances par usure actuellement manquées.

Critère d'optimisation du seuil. Le F1 a été retenu faute de fonction de coût métier explicite, alors qu'il ne reflète aucun arbitrage opérationnel réel.

Colinéarité. Les corrélations fortes entre les deux températures et entre couple et vitesse répartissent arbitrairement l'importance SHAP entre variables redondantes. Ces valeurs mesurent une contribution au sein du modèle et ne doivent pas être lues comme une relation causale.

10. Conclusion

10.1 Réponse à la question de recherche

Sur l'efficacité de la détection. XGBoost atteint une PR-AUC de 0,813 contre 0,034 pour un classifieur aléatoire, soit un pouvoir de discrimination vingt-quatre fois supérieur au hasard. Au seuil ajusté, il détecte 48 défaillances sur 68 en n'émettant que 10 fausses alertes. La détection automatique des risques de panne apparaît donc **opérationnellement viable** sur ce jeu de données, sous réserve de calibrer le seuil sur l'arbitrage métier plutôt que sur une convention statistique.

Sur les facteurs déterminants. Trois variables mécaniques concentrent 75 % de l'importance : le couple (30,8 %), l'usure de l'outil (25,1 %) et la vitesse de rotation (18,8 %). Les températures suivent (22,6 % cumulés), tandis que la qualité du produit s'avère marginale (2,7 %) une fois les conditions de fonctionnement connues.

10.2 Modèle retenu

XGBoost est retenu : meilleure PR-AUC et meilleur rappel à précision comparable une fois le seuil ajusté. La validation croisée place toutefois la forêt aléatoire à un niveau statistiquement équivalent ; l'écart observé sur l'échantillon de test ne saurait être présenté comme une supériorité établie.

10.3 Apport méthodologique

Trois enseignements dépassent le cadre de ce jeu de données.

Le premier concerne le **choix des métriques** : sous forte asymétrie de classes, la ROC-AUC peut atteindre 0,907 pour un modèle émettant une alerte justifiée sur sept. La PR-AUC est seule à refléter la difficulté réelle du problème.

Le deuxième concerne l'**identification des fuites de données** : la présence de variables renseignées postérieurement à l'événement prédit constitue un piège silencieux, dont la détection relève de la compréhension du processus métier et non de l'analyse statistique.

Le troisième concerne l'**adéquation entre modèle et structure du problème** : la supériorité des modèles d'ensemble s'explique ici par la géométrie des régions de défaillance, et non par une capacité d'apprentissage supérieure dans l'absolu.

10.4 Prolongements

1. Construire les variables dérivées (puissance mécanique, écart de températures, interaction usure × couple) et mesurer leur apport par une étude d'ablation.
2. Optimiser les hyperparamètres par recherche aléatoire avec validation croisée sur la PR-AUC.
3. Substituer au F1 une fonction de coût métier explicite et en déduire le seuil optimal.
4. Reproduire le protocole sur des données industrielles réelles afin d'éprouver la validité externe des conclusions.

Références

Jeu de données. Matzka, S. (2020). *AI4I 2020 Predictive Maintenance Dataset*. UCI Machine Learning Repository. https://doi.org/10.24432/C5HS5C

Méthodes. Chen, T. & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. KDD '16. — Lundberg, S. M. & Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions*. NeurIPS 2017. — Saito, T. & Rehmsmeier, M. (2015). *The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets*. PLoS ONE 10(3).

Code et résultats reproductibles. https://github.com/Yvngval/Predictive-Maintenance-Explainable-ML-